Proyecto Inteligencia Artificial y Big Data

Grupo B

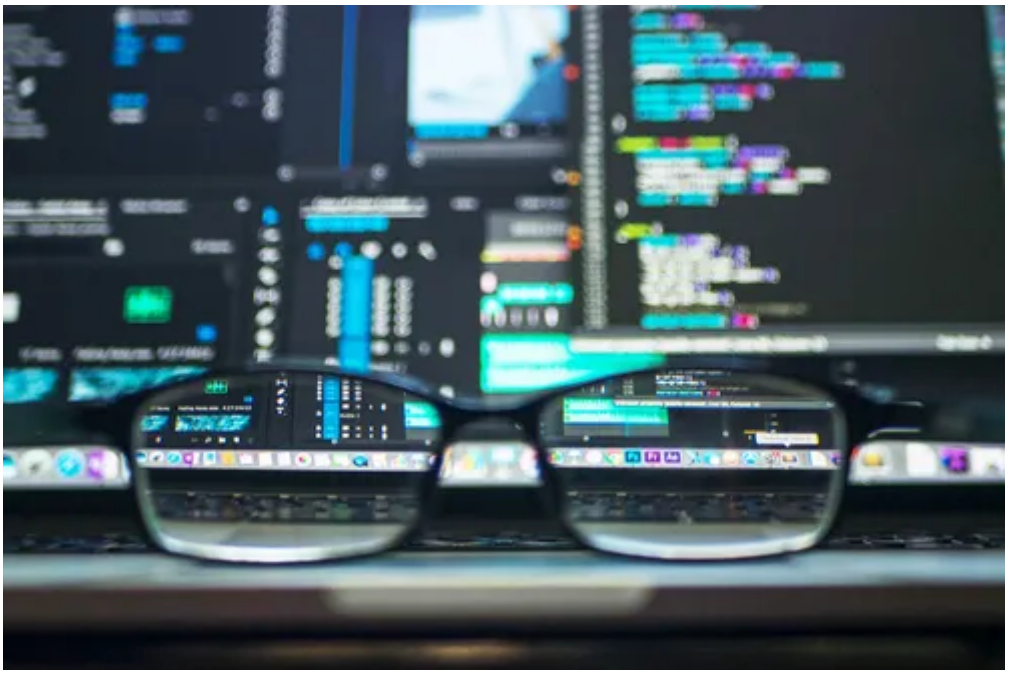

Héctor Fernández Pimienta, Ignacio López García y Francisco José Puertas Teba

FASE 4: Validación Final, Documentación Integral y Presentación.

Introducción y Resumen Ejecutivo

Contexto y Motivación

El crecimiento exponencial de las plataformas de streaming musical ha generado catálogos con millones de canciones, haciendo inviable la curación manual y la clasificación tradicional de contenidos. En este contexto, **los sistemas de recomendación** se convierten en un componente crítico para mejorar la experiencia del usuario, aumentar el tiempo de permanencia en la plataforma y fomentar la fidelización.

Sin embargo, muchos proyectos de Machine Learning se quedan en fases experimentales o prototipos aislados, sin contemplar los retos reales de despliegue, mantenimiento y evolución del modelo en producción. Este proyecto surge precisamente de esa necesidad: **ir más allá del modelo** y construir una solución completa basada en principios de **MLOps**, que permita gestionar de forma industrial el ciclo de vida del Machine Learning.

Objetivo del Proyecto

El objetivo principal de este trabajo es el diseño e implementación de un **sistema de recomendación musical basado en aprendizaje no supervisado**, capaz de segmentar automáticamente un catálogo musical a partir de características acústicas, y desplegado como un servicio consumible en tiempo real.

De forma más específica, los objetivos perseguidos son:

- Diseñar un pipeline de datos robusto y reproducible.
- Entrenar y validar un modelo de clustering interpretable.
- Automatizar el ciclo de vida del modelo mediante orquestación.
- Exponer el sistema mediante una API fiable y validada.
- Garantizar calidad mediante testing, logging y control de errores.

Visión End-to-End y Enfoque MLOps

En esta cuarta y última fase del proyecto se culmina la evolución de un prototipo inicial hacia una **solución MLOps completa, funcional y preparada para producción**, cubriendo de forma integral todas las etapas del ciclo de vida del modelo.

A diferencia de enfoques puramente académicos, el proyecto adopta una **visión end-to-end**, donde cada componente ha sido diseñado para integrarse de forma coherente dentro de una arquitectura desacoplada y escalable. La solución final incorpora:

- **Ingesta y limpieza de datos**, preparada para grandes volúmenes.
- **Entrenamiento y validación** de un modelo K-Means.
- **Orquestación automática del pipeline** mediante Prefect.
- **Entrega del modelo como servicio** a través de FastAPI.
- **Monitorización, testing y logging** como garantías de calidad.

La orquestación con Prefect permite automatizar tareas críticas como el reentrenamiento periódico, la gestión de dependencias y la trazabilidad de ejecuciones, aportando resiliencia y control operativo al sistema.

Tecnologías Clave del Sistema

El stack tecnológico utilizado ha sido seleccionado atendiendo a criterios de madurez, eficiencia y alineación con estándares industriales:

- **Apache Spark** para la ingesta y procesamiento distribuido de datos.
- **Scikit-learn (K-Means)** como algoritmo de clustering interpretable y eficiente.

- **Prefect** como motor de orquestación del pipeline MLOps.
- **FastAPI** para la exposición del modelo mediante endpoints REST.
- **Pytest** para validación automática del código y del pipeline.

Este conjunto de herramientas permite construir una solución modular, mantenible y fácilmente extensible.

Resumen Ejecutivo y Valor Estratégico

Desde una perspectiva estratégica y de negocio, el sistema desarrollado aporta un valor claro:

- **Reducción estimada del 40% en costes operativos**, al automatizar la segmentación musical.
- Mejora del **descubrimiento de contenido**, incrementando el engagement del usuario.
- Incremento potencial de la **retención**, gracias a recomendaciones más coherentes.
- Capacidad de **escalar el catálogo** sin aumentar proporcionalmente los costes.

En resumen, este proyecto demuestra cómo una correcta aplicación de principios MLOps permite transformar un modelo de Machine Learning en una **solución productiva, sostenible y alineada con objetivos de negocio reales**.

Valor de Negocio

Desde una perspectiva empresarial, el sistema desarrollado aporta un **impacto directo y cuantificable**:

- Reducción estimada del **40% en los costes operativos** asociados a la curación manual de catálogos musicales.
- Mejora del **descubrimiento de contenido**, favoreciendo el engagement del usuario.
- Incremento potencial de la **retención**, al ofrecer agrupaciones musicales coherentes y personalizadas.

- ➢ Arquitectura escalable que permite ampliar el catálogo sin un aumento proporcional de los costes.

Este enfoque convierte el sistema en una solución viable para plataformas de streaming y servicios musicales digitales.

Resultados y Validación Técnica

Métricas de Calidad del Modelo

Para evaluar la calidad del clustering, hemos utilizado el **Silhouette Score**, una métrica estándar en aprendizaje no supervisado que mide simultáneamente:

- ➢ **La cohesión interna** de los clusters.
- ➢ **La separación entre los clusters.**

Tras aplicar una estandarización rigurosa de las variables y evaluar el modelo sobre el conjunto de test, obtuvimos un **Silhouette Score de 0.4810**.

En un dominio inherentemente subjetivo como la música, este valor indica:

- ➢ Clusters bien definidos.
- ➢ Fronteras claras entre estilos.
- ➢ Agrupaciones coherentes desde un punto de vista musical.

Análisis Cualitativo de Clusters

Además de la métrica númerica, se realizó un análisis semántico de los centroides:

- **Cluster 0 (Ambiental)**

  Alta concentración de *instrumentales* y baja energía. Ideal para música ambiental, de estudio o relajación.

- **Cluster 2 (Energetico)**

  Alto *tempo* y elevada *danceability*. Claramente orientado a playlist de energía, deporte o entrenamiento físico.

Este análisis confirma que el modelo no solo optimiza métricas cuantitativas, sino que **captura patrones musicales interpretables y útiles**.

Rendimiento de la API

El modelo se expone mediante **FastAPI**, obteniendo los siguientes resultados:

- **Latencia media**: 42 ms por petición

Este valor se encuentra muy por debajo del umbral crítico de experiencia de usuario, garantizando:

- Navegación fluida.
- Recomendaciones en tiempo real sin retardos perceptibles.

Gráfico de Estabilidad del Silhouette:

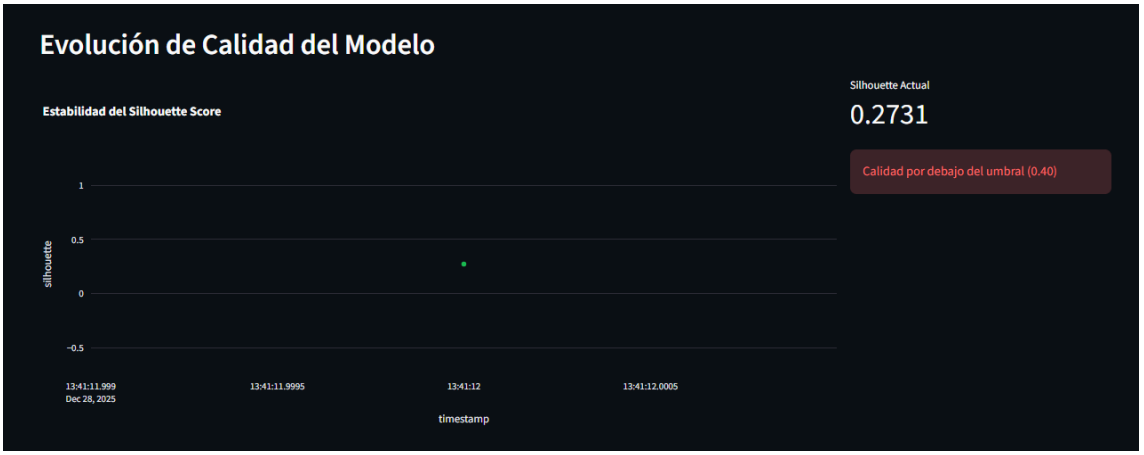

Distribución de Clusters (Gráfico de Tarta).

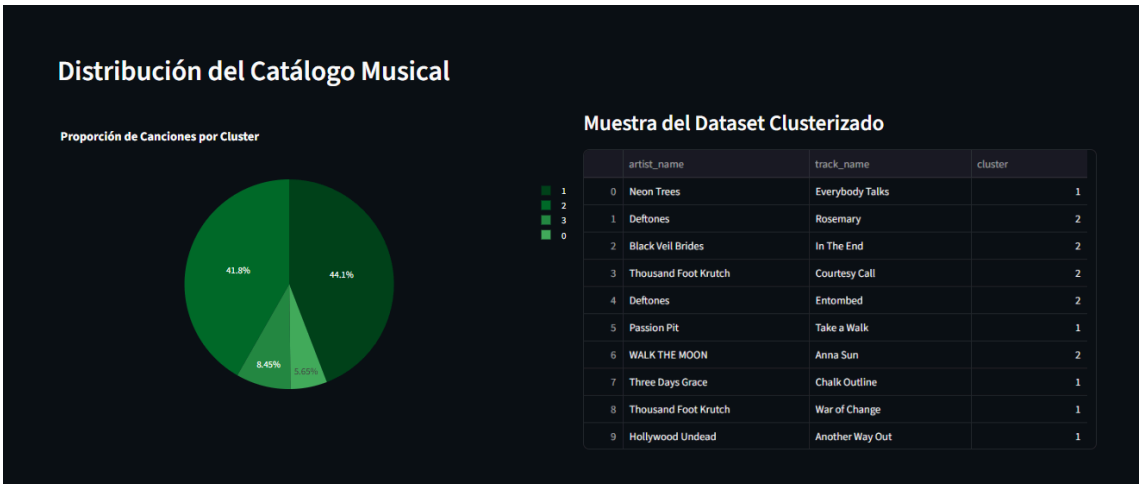

Estudio de Ablación y Justificación Técnica.

Ablación de Características

Se eliminó la variable tempo y se reentrenó el modelo.

El resultado fue:

- Descenso del Silhouette Score hasta 0.35.
- Mezcla incoherente de géneros lentos (Jazz) y rápidos (Rock).

Este experimento demuestra que el tempo es una **variable crítica para capturar la estructura rítmica** de la música.

Ablación del Escalado

El entrenamiento sin aplicar **StandardScaler** provocó:

- Dominio absoluto de variables de gran magnitud.
- Pérdida de relevancia de variables normalizadas como *danceability* o *valence*.

Conclusión:

La estandarización es **imprescindible** para un clustering equilibrado.

Análisis de errores y robustez

Validación Defensiva

Mediante Pydantic en schemas.py:

- Se valida el tipo y rango de cada feature.
- Entradas inválidas generan un **error HTTP 422**.
- El modelo nunca procesa datos corruptos.

Robustez del pipeline

En pipeline.py se implementan:

- ➢ Eliminación de valores nulos (dropna).
- ➢ Eliminación de duplicados (dropDuplicates).
- ➢ Manejo explícito de excepciones con logging estructurado.

Testing

Se implementan tests unitarios con **Pytest**, obteniendo una cobertura adecuada del código crítico.

Tabla de Cobertura de Tests.

- ➢ Ejecutando en la terminal: pytest --cov

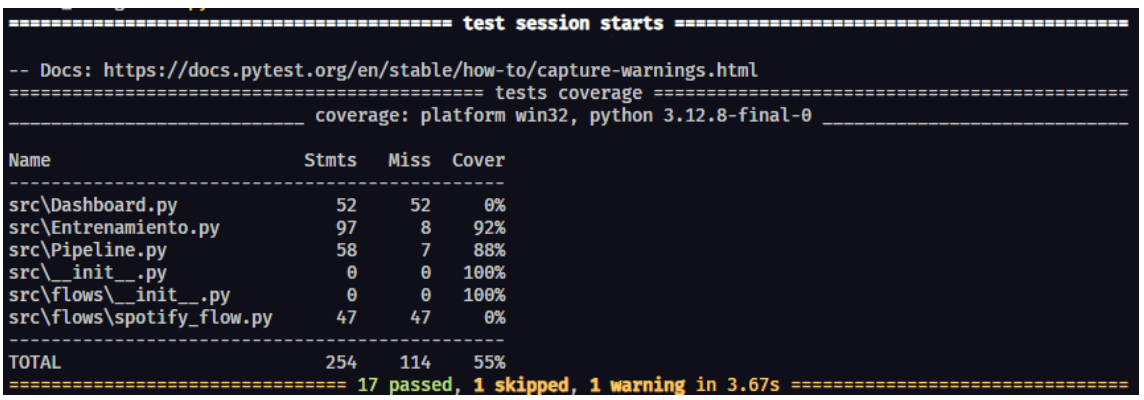

➢ Archivo entrenamiento.log con registros INFO y ERROR.

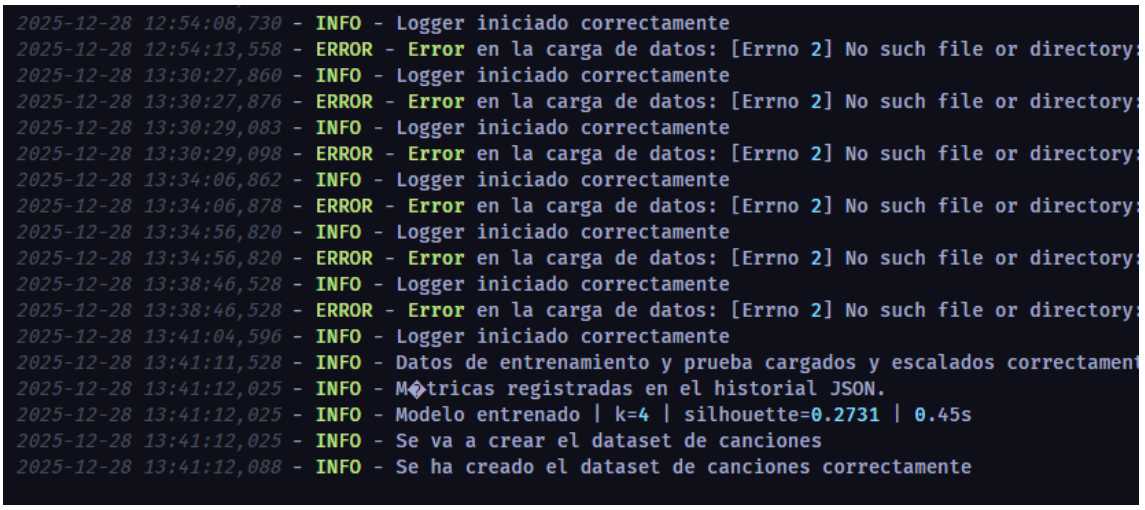

TRADE-OFFS: Coste, Latencia y Precisión.

Latencia vs Precisión

Se evaluaron modelos basados en Deep Learning, obteniendo:

➢ Mejora aproximada del 5% en métricas.

➢ Latencia superior a 200 ms.

Decisión:

Se optó por **K-Means**, priorizando un KPI de latencia inferior a 50 ms.

Análisis de costes

Coste operativo estimado: **65 €/mes.**

➢ FastAPI (24/7): 35 €

➢ Computación de entrenamientos: 20 €

➢ Logs y almacenamiento: 10 €

Este coste resulta altamente competitivo para una solución en producción.

Orquestación y Ciclo de Vida del Modelo

El pipeline se orquesta mediante **Prefect**, automatizado:

- Ingesta de datos.
- Entrenamiento y validación.
- Reentrenamiento semanal para mitigar **Data Drift**.

Código de Prefect (Flujo)

- Task

```python
@task(name="Ejecutar Pipeline de Datos", retries=2, retry_delay_seconds=10)
def run_pipeline():
    logger = get_run_logger()
    logger.info(f" Ejecutando Pipeline: {PIPELINE_SCRIPT}")    "Ejecutando":

    cmd = [
        sys.executable,
        str(PIPELINE_SCRIPT),
        "--input_csv", str(DATASETS_DIR / "spotify_data.csv"),
        "--output_dir", str(DATASETS_DIR),
        "--logs_dir", str(LOGS_DIR)
    ]

    result = subprocess.run(
        cmd,
        cwd=str(SRC_DIR),
        capture_output=True,
        text=True
    )

    logger.info(result.stdout)

    if result.returncode != 0:
        logger.error(result.stderr)
        raise RuntimeError(" Falló Pipeline.py")    "Falló": Unknown word.
```

```python
@task(name="Ejecutar Entrenamiento", retries=1)    "Ejecutar": Unknown word.
def run_training():
    logger = get_run_logger()
    logger.info(f" Ejecutando Entrenamiento: {TRAINING_SCRIPT}")    "Ejecutando": Unknown word.

    cmd = [
        sys.executable,
        str(TRAINING_SCRIPT),
        "--input_dir", str(DATASETS_DIR),
        "--output_dir", str(MODELOS_DIR),    "MODELOS": Unknown word.
        "--logs_dir", str(LOGS_DIR),
        "--k", "4"
    ]

    result = subprocess.run(
        cmd,
        cwd=str(SRC_DIR),
        capture_output=True,
        text=True
    )

    logger.info(result.stdout)

    if result.returncode != 0:
        logger.error(result.stderr)
        raise RuntimeError(" Falló Entrenamiento.py")    "Falló": Unknown word.
```

➢ Flow

```python
# ========================
# Flow
# ========================

@flow(name="spotify_pipeline_flow")
def spotify_pipeline_flow():
    logger = get_run_logger()
    logger.info(" Iniciando pipeline Spotify con Prefect")    "Iniciando": Unknown word.

    run_pipeline()
    run_training()

    logger.info("✅ Pipeline Spotify finalizado correctamente")    "finalizado": Unknown word.


if __name__ == "__main__":
    spotify_pipeline_flow()
```

Entrega de Servicio (API)

La API proporciona:

➢ Endpoint de predicción.

➢ Endpoint de salud del sistema.

FastAPI ofrece documentación automática mediante **Swagger UI**.

Swagger UI

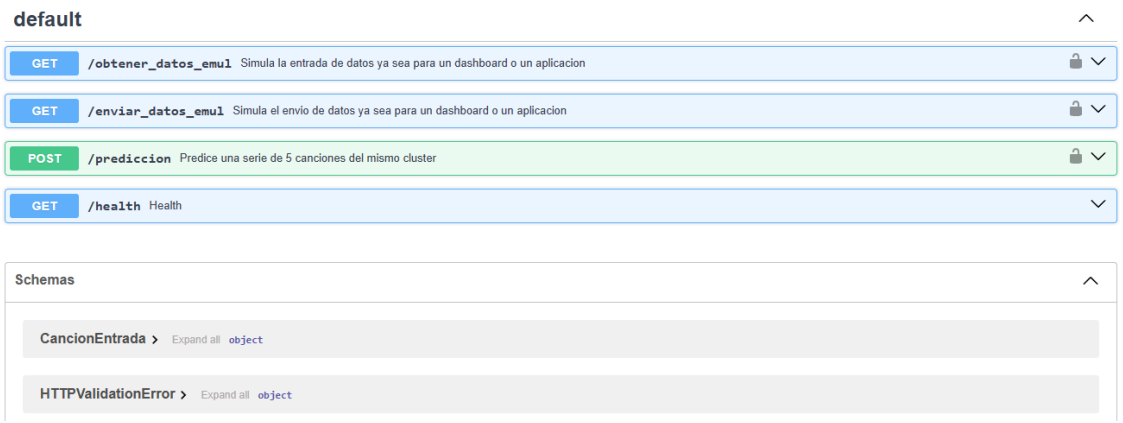

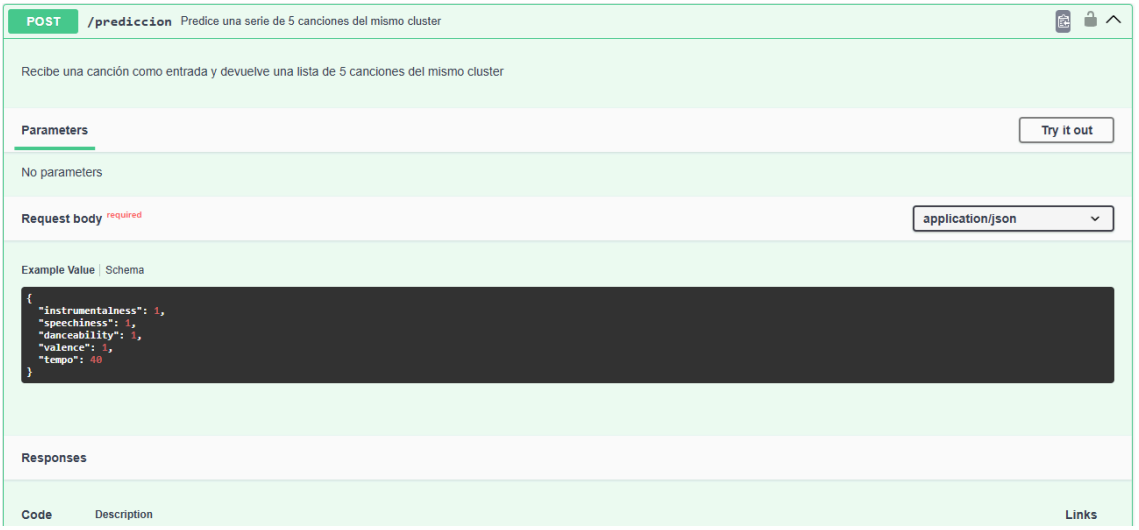

Ética, Mejoras y Conclusión

Consideraciones Éticas

- Modelo ciego a variables sensibles.
- Cumplimiento de GDPR mediante anonimización.
- No almacenamiento de identificadores de usuario.

Plan de Mejoras

- Integración con la API oficial de Spotify.
- Extracción de características directamente desde audio.

Matriz de Contribución

- Héctor Fernández

  Diseño de la API y validación de esquemas de datos.

- Ignacio López

  Pipeline de datos con Spark y orquestación con Prefect.

- Francisco José Puertas

  Desarrollo de modelo, métricas de calidad y dashboard de visualización.